


# Time Series Anomaly Detection

## LSTM + AE


- 시계열 모델링을 위한 데이터구조
- RNN 및 LSTM의 기본 개념을 간략하게 살펴보고,
- LSTM+AE를 이용한 이상탐지를 수행해 봅니다.

# Sequential Data

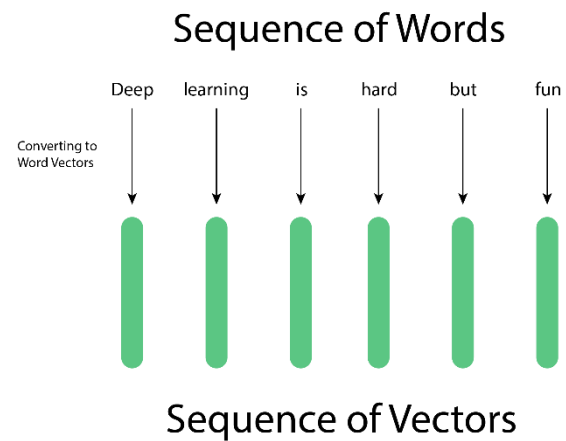
Voice



Stock Data



Sentence



# 데이터 전처리

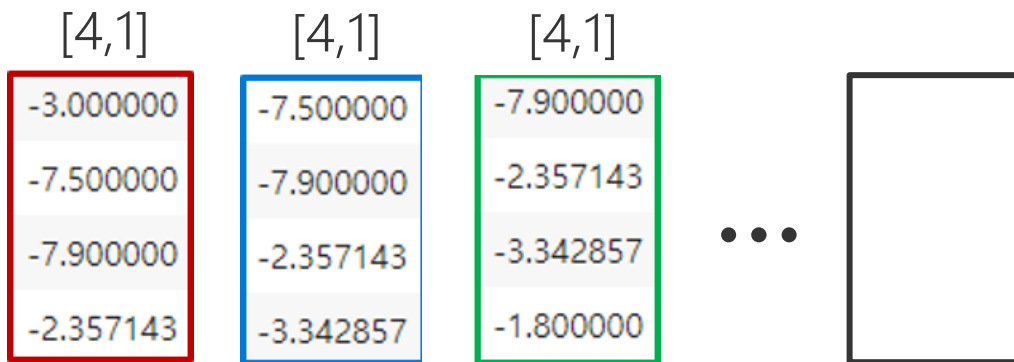
✓ 주간기온을 예측하는데 과거 어느 정도의 기간이면 적절할까?

	year	week	AvgTemp
0	2010	1	-3.000000
1	2010	2	-7.500000
2	2010	3	-7.900000
3	2010	4	-2.357143
4	2010	5	-3.342857
5	2010	6	-1.800000
6	2010	7	-0.314286
7	2010	8	-2.142857
8	2010	9	4.400000
9	2010	10	7.057143

# 데이터 전처리① : RNN을 위한 데이터구조

✓ 예를 들어, 과거 4주간의 데이터로 예측할 때, **x의 구조는?**

	year	week	AvgTemp
0	2010	1	-3.000000
1	2010	2	-7.500000
2	2010	3	-7.900000
3	2010	4	-2.357143
4	2010	5	-3.342857
5	2010	6	-1.800000
6	2010	7	-0.314286
7	2010	8	-2.142857
8	2010	9	4.400000
9	2010	10	7.057143



몇 개?

$$\text{Total} - \text{timestep} + 1 = \#$$


3차원 데이터 :  $[\#, 4, 1]$

# 데이터 전처리①: RNN을 위한 데이터구조

✓ 예를 들어, 과거 4주간의 데이터로 예측할 때, **y의 구조는?**

	year	week	AvgTemp
0	2010	1	-3.000000
1	2010	2	-7.500000
2	2010	3	-7.900000
3	2010	4	-2.357143
4	2010	5	-3.342857
5	2010	6	-1.800000
6	2010	7	-0.314286
7	2010	8	-2.142857
8	2010	9	4.400000
9	2010	10	7.057143

	year	week	AvgTemp
0	2010	1	-3.000000
1	2010	2	-7.500000
2	2010	3	-7.900000
3	2010	4	-2.357143
4	2010	5	-3.342857
5	2010	6	-1.800000
6	2010	7	-0.314286
7	2010	8	-2.142857
8	2010	9	4.400000
9	2010	10	7.057143



# 데이터 전처리② : 스케일링

## 2차원 X

### 1) 데이터 분할

### 2) 스케일링

- train set으로 Scaler 생성
- 전체 데이터에 적용

## 3차원 X ①

### 1) 데이터 분할

### 2) 스케일링

- train set으로 Scaler 생성
- 전체 데이터에 적용

### 3) 2차원 → 3차원 변환

3차원 변환 과정에서 샘플의 초기 데이터를 사용하지 못하게 됨.

## 3차원 X ②

### 1) 2차원 → 3차원 변환

### 2) 데이터 분할

### 3) 스케일링

- train set을 다시 2차원으로 변환 후 Scaler 생성
- 3차원 데이터에 적용

변환 코드, 3차원 적용 코드 필요.

# 데이터 전처리② : 스케일링

## ✓ 3차원 x ①

- train : val : test 분할 후
- 스케일링
- 3차원으로 변환


## ✓ 문제점

- 데이터셋의 초기 데이터 손실

	x1	x2	x3	y
train	1.016235	-4.058394	-1.097158	0
	1.005602	-3.876199	-1.074373	0
	0.933933	-3.868467	-1.249954	0
	0.892311	-13.332664	-10.006578	1
	0.020062	-3.987897	-1.248529	0
	-0.109346	-5.071100	-2.409911	0
	-0.098179	-4.070966	-3.268804	0
	0.054564	-4.130103	-3.727432	0
	0.418907	-4.042599	-3.887028	0
	0.306778	-3.721405	-4.060685	0
validation	0.812949	-3.723105	-4.327446	0
	1.016334	-3.009178	-4.315049	0
	0.981237	-2.407708	-4.768463	0
	1.144511	-2.405206	-4.769564	0

# Recurrent Neural Networks



- ✓ 문제를 해결하기 위한, 의미 있는 기간 단위로 나눔
  - 예, 과거 20일 단위(기간)의 정보를 이용하여 다음날의 주가를 예측한다.  
데이터셋에서 20개의 행을 의미, timesteps = 20
- ✓ 각 단계(Time Step)별로 학습하고 결과를 다음 단계로 전달





# Recurrent Neural Networks

✓ 과거의 정보를 현재에 반영해 학습하도록 설계



# Simple RNN

## ✓ 모델링 & 학습

```
1 np.random.seed(2021)
2 tf.random.set_seed(2021)
3
4 # 세션클리어
5 keras.backend.clear_session()
6
7 # Sequential 모델 선언 + layer 추가하기(한꺼번에)
8 model = keras.models.Sequential([
9     keras.layers.SimpleRNN(10, input_shape=[None, 1]),
10    keras.layers.Dense(1)
11 ])
12
13 model.compile(loss="mse", optimizer=keras.optimizers.Adam(lr=0.005))
14 history = model.fit(x_train, y_train, epochs=20, validation_data=(x_val, y_val))
```

Model: "sequential"

Layer (type)	Output Shape	Param #
simple_rnn (SimpleRNN)	(None, 10)	120
dense (Dense)	(None, 1)	11

Total params: 131  
Trainable params: 131  
Non-trainable params: 0

Node 수(뉴런의 개수)

[time\_step수, feature수]

# Deep RNN

## ✓ 모델링 & 학습

	year	week	AvgTemp
0	2010	1	-3.000000
1	2010	2	-7.500000
2	2010	3	-7.900000
3	2010	4	-2.357143
4	2010	5	-3.342857
5	2010	6	-1.800000
6	2010	7	-0.314286
7	2010	8	-2.142857
8	2010	9	4.400000
9	2010	10	7.057143

```
SimpleRNN(10, input_shape=[None, 1], return_sequences=False)
```

t=1

-3.000000

t=2


-7.500000

t=3

-7.900000

t=4

-2.357143



# Deep RNN

## ✓ 모델링 & 학습

	year	week	AvgTemp
0	2010	1	-3.000000
1	2010	2	-7.500000
2	2010	3	-7.900000
3	2010	4	-2.357143
4	2010	5	-3.342857
5	2010	6	-1.800000
6	2010	7	-0.314286
7	2010	8	-2.142857
8	2010	9	4.400000
9	2010	10	7.057143

```
SimpleRNN(10, input_shape=[None, 1], return_sequences=True)  
SimpleRNN(10, return_sequences=False),
```

t=1

-3.000000

t=2

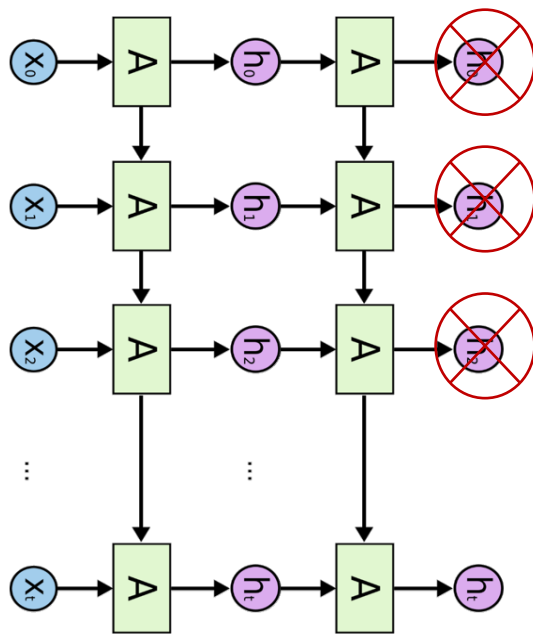
-7.500000

t=3

-7.900000

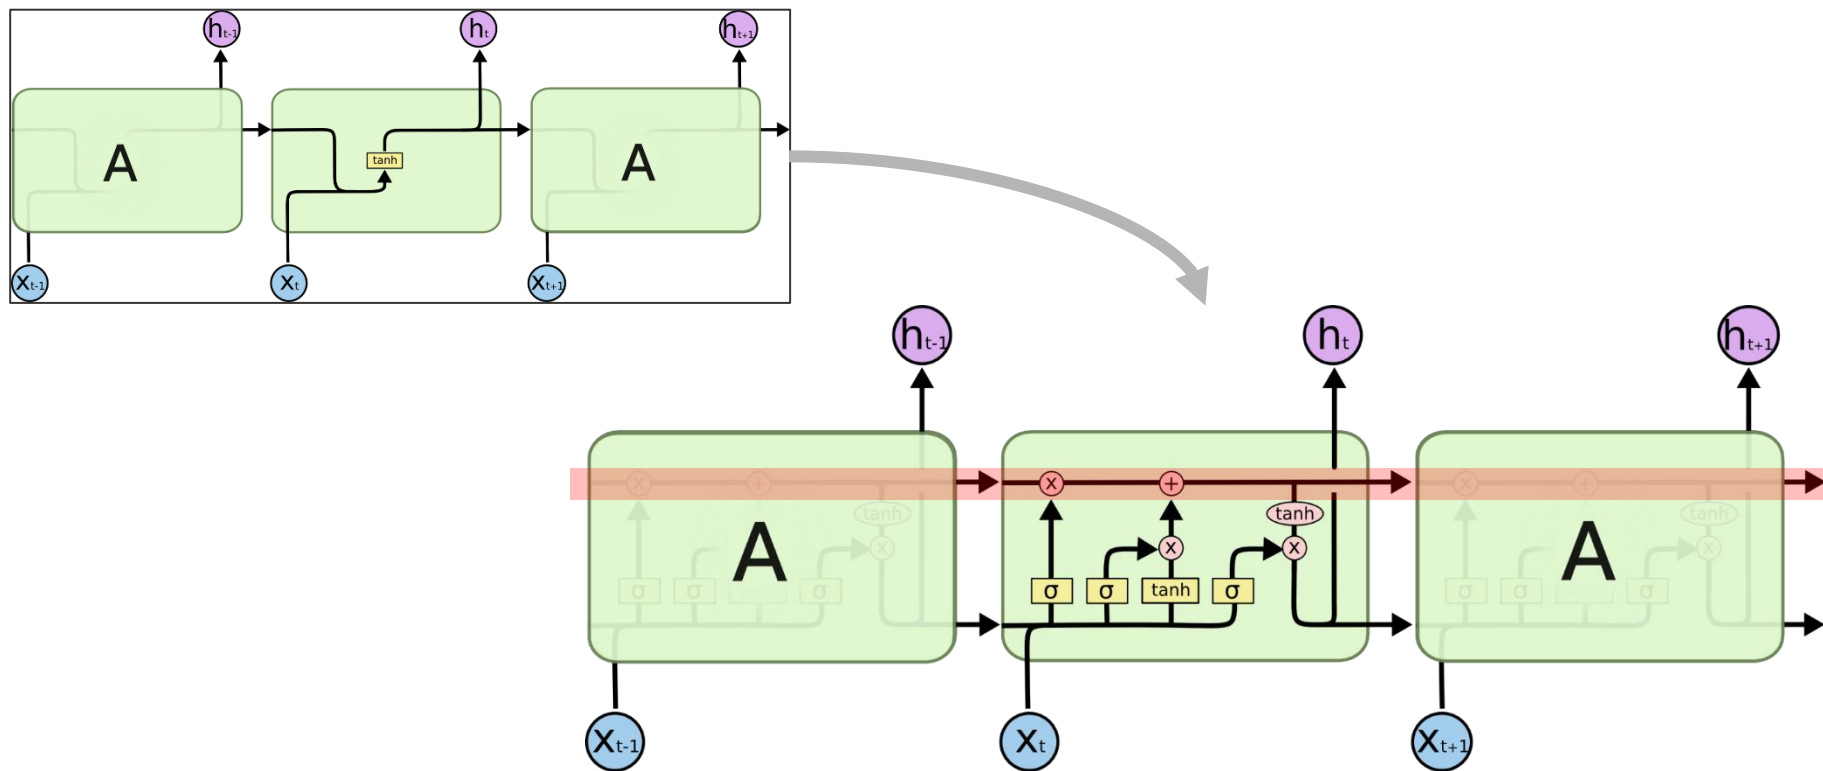
t=4

-2.357143

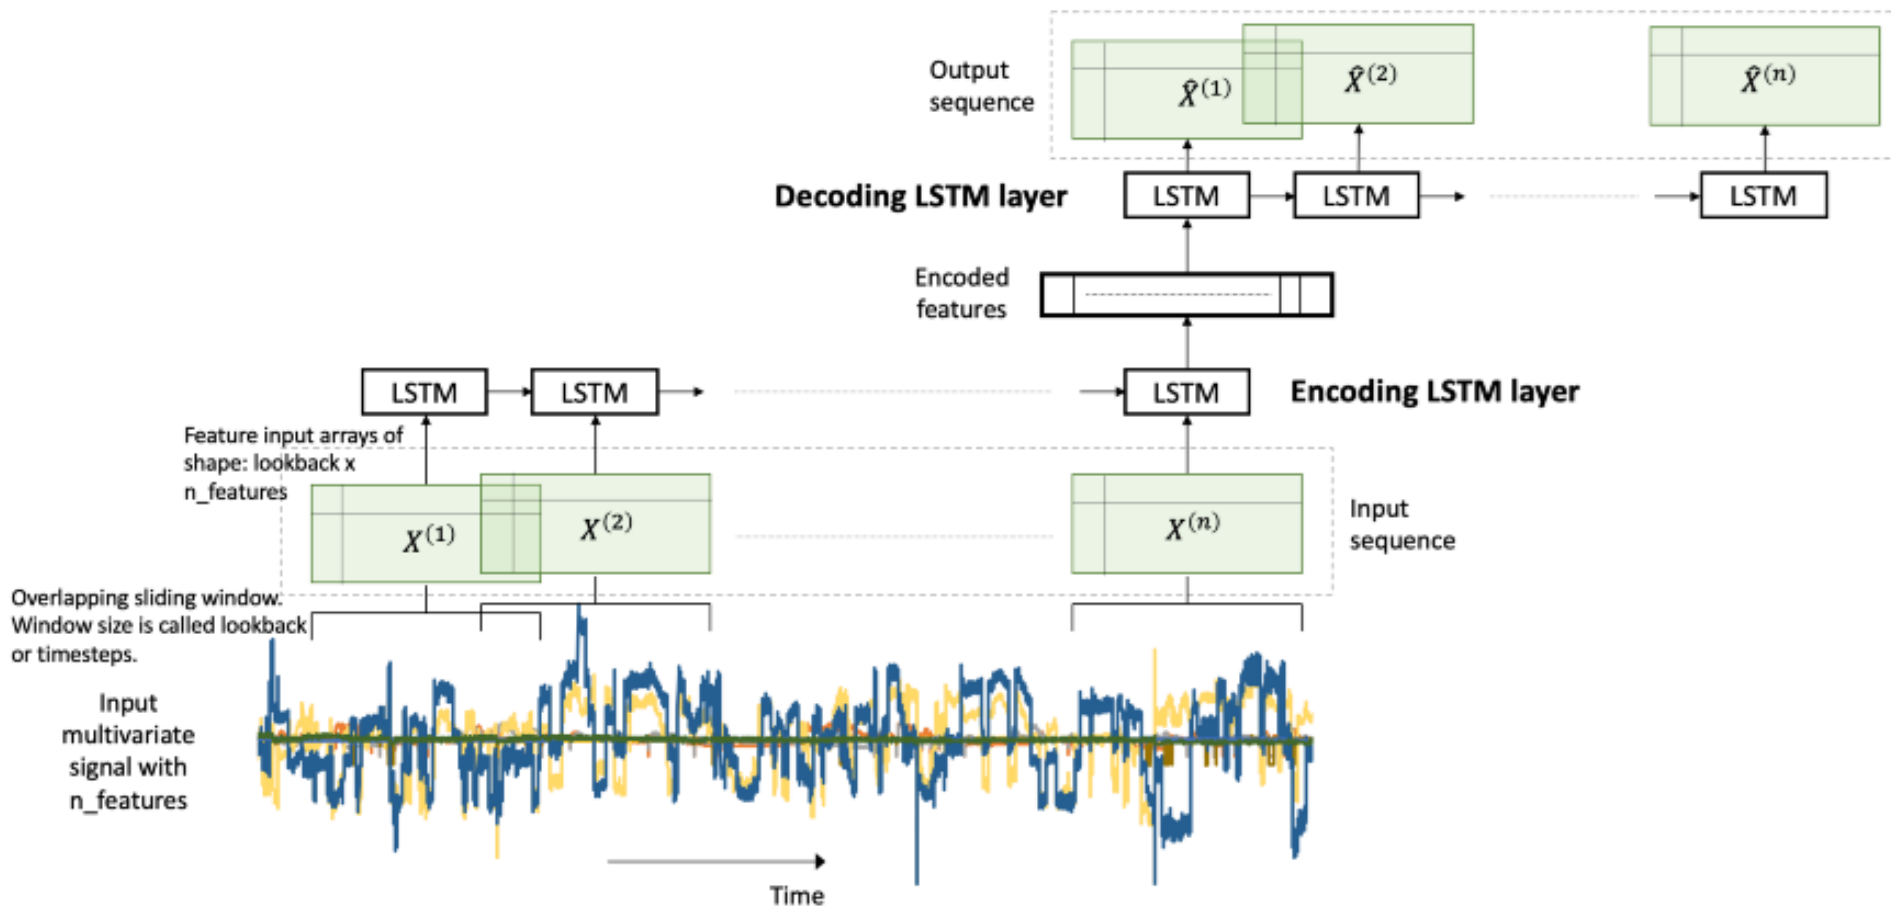


# RNN의 Vanishing Gradient 문제

- ✓ 극복하기 위해서 고안된 것이 바로 LSTM
- ✓ RNN의 hidden state에 cell state(장기 기억 메모리)를 추가한 구조



# LSTM + AE



# AE와 LSTM+AE 코드 구조 비교

## AE

```
6 # Encoder
7 input_layer = Input(shape=(input_dim, ))
8 encoder = Dense(32, activation="relu")(input_layer)
9 encoder = Dense(16, activation="relu")(encoder)
10 # Decoder
11 decoder = Dense(32, activation="relu")(encoder)
12 decoder = Dense(input_dim)(decoder)
13 autoencoder = Model(inputs=input_layer, outputs=decoder)
14 autoencoder.summary()
```

Model: "model\_1"

Layer (type)	Output Shape	Param #
input_2 (InputLayer)	[(None, 59)]	0
dense_4 (Dense)	(None, 32)	1920
dense_5 (Dense)	(None, 16)	528
dense_6 (Dense)	(None, 32)	544
dense_7 (Dense)	(None, 59)	1947

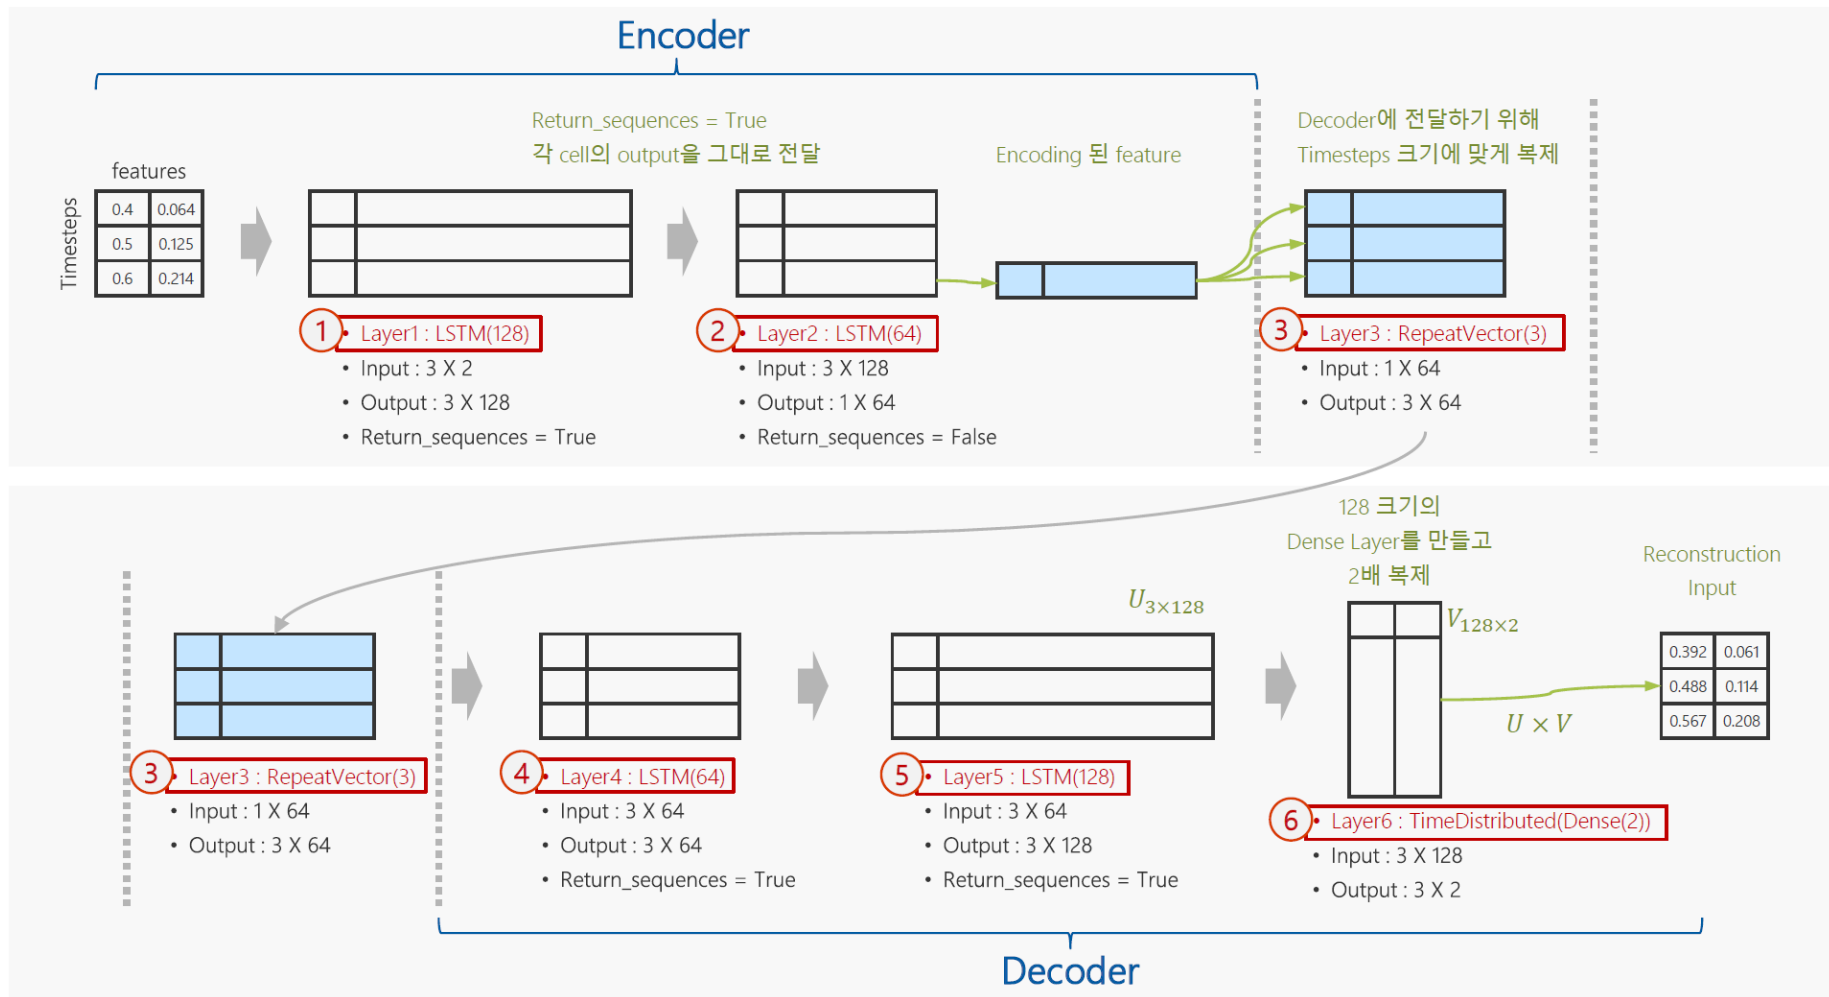
## LSTM + AE

```
1 # Encoder
2 input_layer = Input(shape=(timestep, n_features))
3 encoder = LSTM(32, return_sequences=True)(input_layer)
4 encoder = LSTM(16, return_sequences=False)(encoder)
5 encoder = RepeatVector(timestep)(encoder)
6 # Decoder
7 decoder = LSTM(16, return_sequences=True)(encoder)
8 decoder = LSTM(32, return_sequences=True)(decoder)
9 decoder = TimeDistributed(Dense(n_features))(decoder)
10 lstm_ae = Model(inputs=input_layer, outputs=decoder)
11 lstm_ae.summary()
```

Model: "model"

Layer (type)	Output Shape	Param #
input_1 (InputLayer)	[(None, 10, 59)]	0
lstm_6 (LSTM)	(None, 10, 32)	11776
lstm_7 (LSTM)	(None, 16)	3136
repeat_vector_1 (RepeatVector)	(None, 10, 16)	0
lstm_8 (LSTM)	(None, 10, 16)	2112
lstm_9 (LSTM)	(None, 10, 32)	6272
time_distributed_1 (TimeDistributed)	(None, 10, 59)	1947

# LSTM + AE 구조





# return\_sequences

## ✓ return\_sequences

- True : 입력 데이터의 차원 유지, 각 timestep마다 생성된 hidden state 값을 사용.
- False : 입력 데이터의 차원이 1차원으로 줄어 듦.  
가장 마지막 timestep에 의해 만들어진 hidden state 값을 사용.

```
# Encoder
input_layer = Input(shape=(timestep, n_features))
encoder = LSTM(128, return_sequences=True)(input_layer)
encoder = LSTM(64, return_sequences=False)(encoder)
encoder = RepeatVector(timestep)(encoder)
```



Return\_sequences = True



Return\_sequences = False

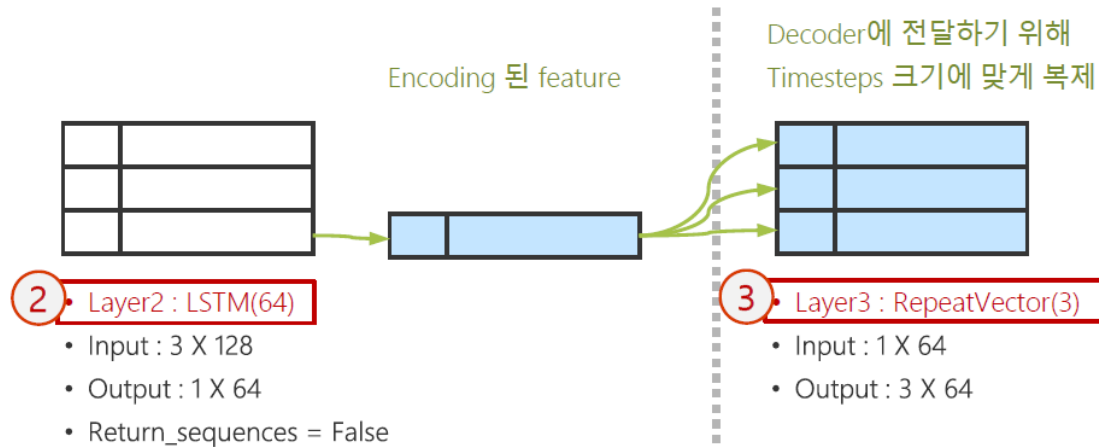
# RepeatVector

## ✓ RepeatVector( *timestep* )

- return\_sequences = False로 1차원이 된 데이터를
- 다음 LSTM으로 넘기기 위해 timestep 수 만큼 2차원 형태로 Replication.
- Encoder와 Decoder를 연결하는 bridge 역할

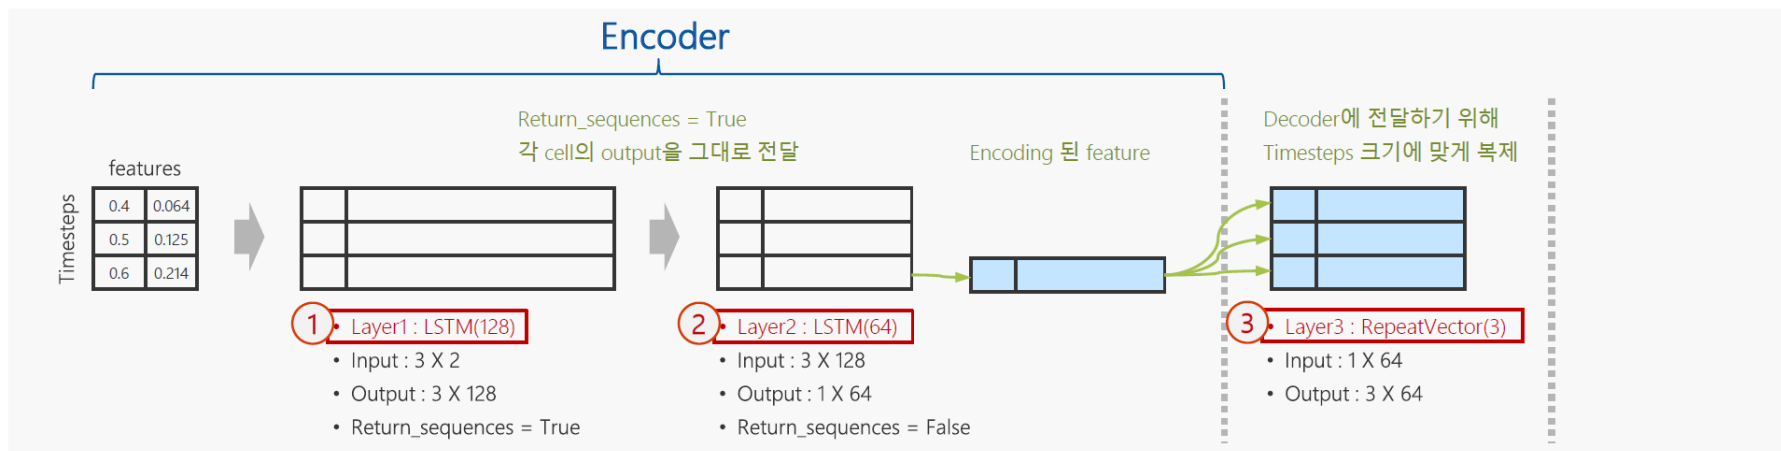
# Encoder

```
input_layer = Input(shape=(timestep, n_features))  
encoder = LSTM(128, return_sequences=True)(input_layer)  
encoder = LSTM(64, return_sequences=False)(encoder)  
encoder = RepeatVector(timestep)(encoder)
```



# Encoder

```
# Encoder
input_layer = Input(shape=(timestep, n_features))
① encoder = LSTM(128, return_sequences=True)(input_layer)
② encoder = LSTM(64, return_sequences=False)(encoder)
③ encoder = RepeatVector(timestep)(encoder)
```

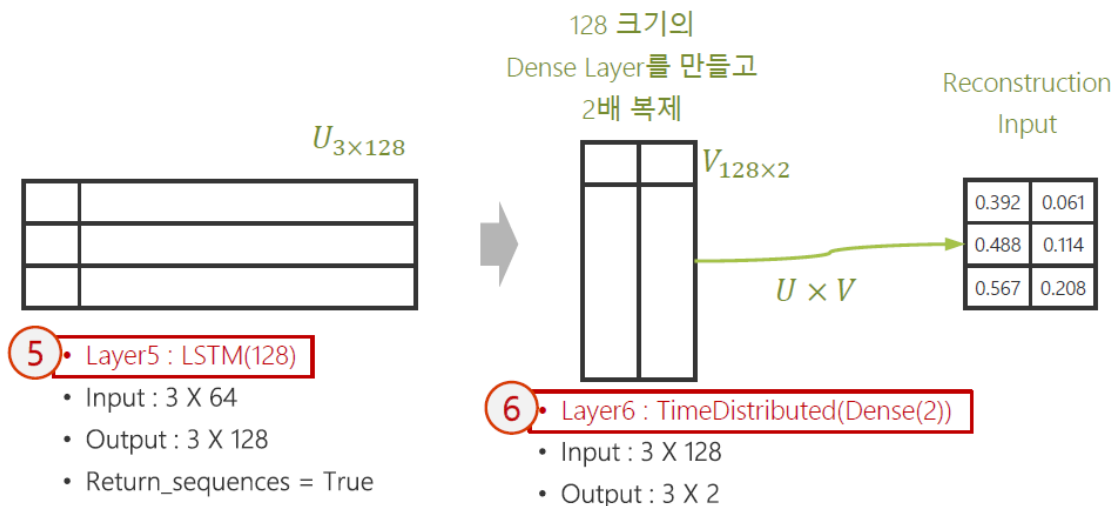


②의 Output 을 압축된 특징벡터라고 부른다. → 다른 지도학습이나 비지도 학습을 위해 사용될 수 있음.

# TimeDistributed

- 이전 레이어에서 출력된 피쳐 수와 동일한 길이의 벡터를 생성하고,
- Input 데이터의 feature 수 만큼 복제하여 행렬을 생성.
- Input의 shape 와 동일하게 출력

```
# Decoder
decoder = LSTM(64, return_sequences=True)(encoder)
decoder = LSTM(128, return_sequences=True)(decoder)
decoder = TimeDistributed(Dense(n_features))(decoder)
```

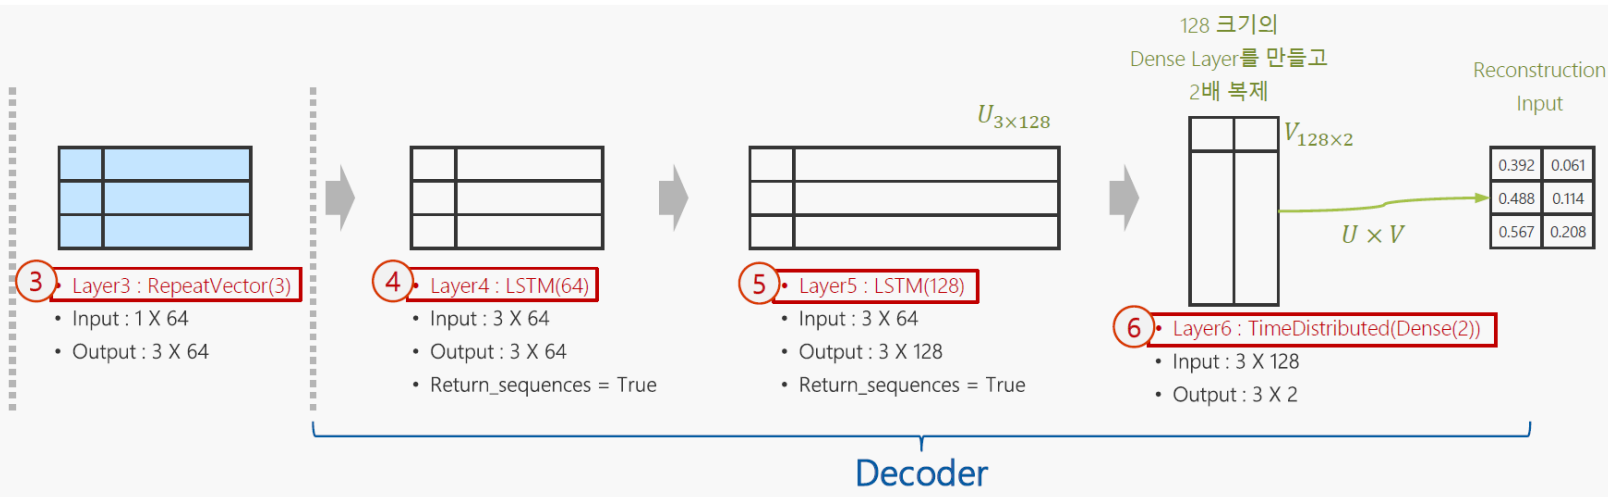


# Decoder

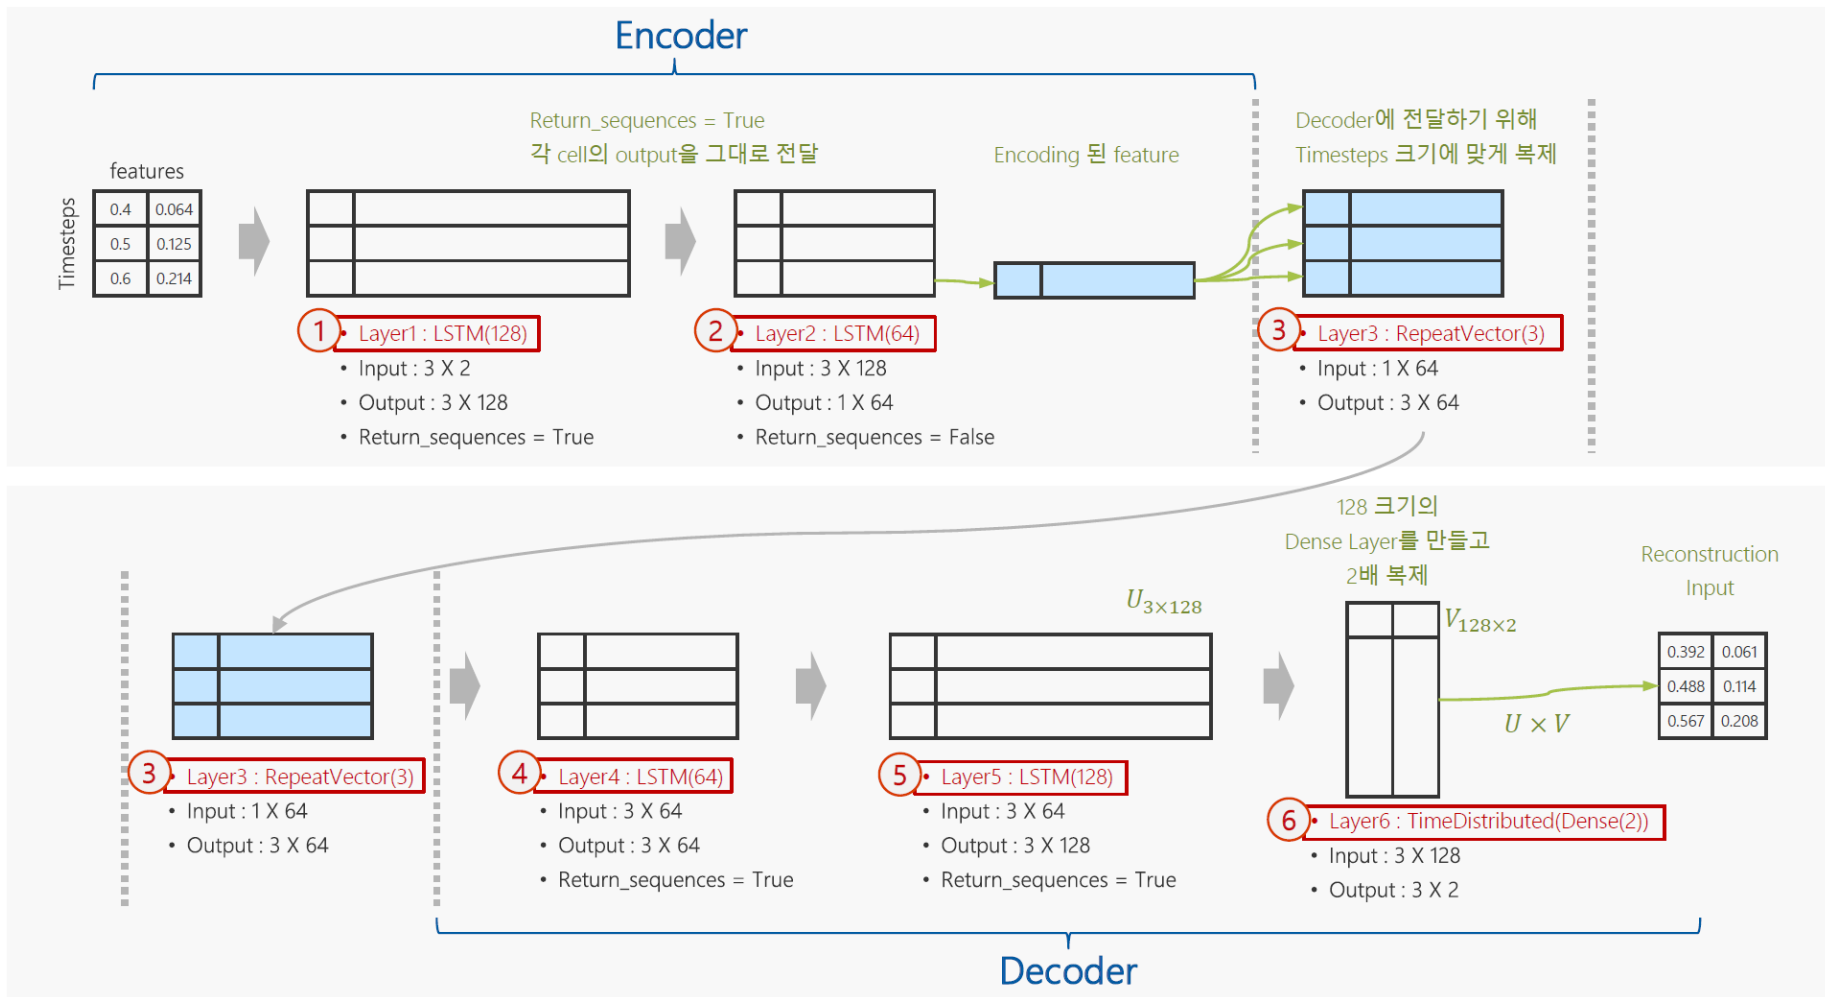
- Decoder는 encoder 구조의 역(inverse) 입니다.
- 마지막은 Input 과 동일한 구조로 Output 을 만들어 냅니다.

# Decoder

```
④ decoder = LSTM(64, return_sequences=True)(encoder)
⑤ decoder = LSTM(128, return_sequences=True)(decoder)
⑥ decoder = TimeDistributed(Dense(n_features))(decoder)
```



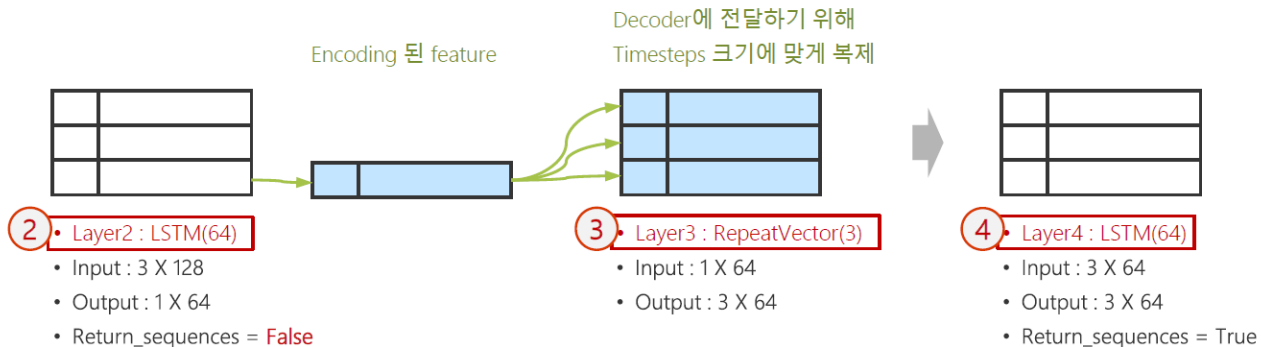
# LSTM + AE 구조 - Review



# LSTM + AE 구조의 변형

## 방법1

압축된 Layer에서  
마지막 Output만 사용해서  
Decoding



## 방법2

압축된 Layer에서  
각 Time step 별 Output을  
모두 사용해서 Decoding

